Convolution ve Softmax Fonksiyonlarının Matematiksel İncelenmesi

1. Convolution İşlemi

Convolutional Neural Network (CNN) mimarisinin temelini oluşturan işlem **convolution** işlemidir. Bu işlem, giriş verisi üzerinde küçük bir filtre (kernel) kullanarak yerel özellikleri çıkarmayı amaçlar. Özellikle görüntü işleme problemlerinde kenar, köşe ve doku gibi özelliklerin öğrenilmesini sağlar.

Matematiksel olarak convolution işlemi aşağıdaki şekilde ifade edilir:

$$o(i,j,k) = \Sigma(u=0\rightarrow F-1)\ \Sigma(v=0\rightarrow F-1)\ \Sigma(c=0\rightarrow C-1)\ x(i+u, j+v, c) \cdot w(u, v, c, k) + b_k$$

Bu ifadede kullanılan değişkenler şunlardır:

x : giriş matrisi (yükseklik × genişlik × kanal)

w : filtre ağırlıkları (kernel)

b_k : bias değeri

o(i,j,k) : elde edilen feature map değeri

Bu işlemde filtre, giriş görüntüsü üzerinde kaydırılır. Filtre ile giriş matrisinin aynı konumdaki elemanları çarpılır ve elde edilen değerler toplanır. Sonuç olarak **feature map** adı verilen yeni bir matris elde edilir.

---

2. Stride ve Padding

Convolution işleminin çıktısını belirleyen iki önemli parametre vardır: **stride** ve **padding**.

Stride

Stride, filtrenin giriş görüntüsü üzerinde kaç piksel adım ile ilerleyeceğini belirler.

Stride = 1 → filtre her pikselde hareket eder
Stride = 2 → filtre iki pikselde bir hareket eder

Stride değeri büyüdükçe elde edilen feature map boyutu küçülür.

Padding

Padding, giriş matrisinin etrafına sıfırlar eklenmesi işlemidir.

Padding kullanılmasının iki temel amacı vardır:

1. Kenar bölgelerde oluşabilecek bilgi kaybını azaltmak
2. Convolution işlemi sonrasında elde edilen feature map boyutunu korumak

Örneğin 5×5 boyutunda bir görüntüye padding = 1 uygulanırsa, giriş boyutu şu şekilde olur:

5×5 → 7×7

---

3. Convolution Çıkış Boyutunun Hesaplanması

Bir convolution katmanının çıkış boyutu aşağıdaki formül ile hesaplanır:

$$O = (N - F + 2P) / S + 1$$

Burada:

N : giriş boyutu
F : filtre boyutu
P : padding değeri
S : stride değeri
O : elde edilen çıkış boyutu

Örnek Hesaplama

Giriş Parametreleri

Parametre	Değer
Giriş matrisi	5 × 5 × 3
Filtre boyutu	3 × 3
Padding	1
Stride	2

Çıkış Boyutu Hesaplama Adımları

Adım	İşlem	Sonuç
1	O = (N − F + 2P) / S + 1	Formül
2	O = (5 − 3 + 2×1) / 2 + 1	Değerler yerine yazılır
3	O = (5 − 3 + 2) / 2 + 1	Sadeleştirme
4	O = 4 / 2 + 1	İşlem
5	O = 2 + 1	İşlem
6	O = 3	Sonuç

Sonuç

Özellik	Boyut
Feature Map Boyutu	3 × 3

Birden Fazla Filtre Kullanımı

Filtre Sayısı	Çıktı Boyutu
1 filtre	3 × 3 × 1
10 filtre	3 × 3 × 10

---

4. Softmax Fonksiyonu

Softmax fonksiyonu, çok sınıflı sınıflandırma problemlerinde modelin çıktısını olasılık dağılımına dönüştürmek için kullanılır.

Sinir ağının son katmanında elde edilen değerler **logit** olarak adlandırılır. Bu değerler doğrudan olasılık değildir. Softmax fonksiyonu bu değerleri normalize ederek olasılık değerlerine dönüştürür.

Matematiksel olarak softmax fonksiyonu şu şekilde ifade edilir:

$P(y = i) = e^{(z_i)} / \Sigma_{(j=1 \to K)} e^{(z_j)}$

Burada:

z_i : i. sınıfın logit değeri
K : toplam sınıf sayısı
e : Euler sayısı

---

5. Softmax Hesaplama Adımları

Softmax hesaplama işlemi üç temel adımdan oluşur.

1. Üstel fonksiyon uygulama

Her logit değeri için üstel fonksiyon uygulanır:

$e^{(z_1)}, e^{(z_2)}, ..., e^{(z\square)}$

Bu işlem negatif değerleri pozitife çevirir ve büyük değerleri daha da büyüterek sınıflar arasındaki farkı belirginleştirir.

---

2. Toplam hesaplama

Tüm üstel değerler toplanır:

$S = \Sigma_{(j=1 \to K)} e^{(z_j)}$

---

3. Normalizasyon

Her değer toplam değere bölünerek olasılık elde edilir:

$P(y = i) = e^{(z_i)} / S$

Bu işlem sonucunda tüm olasılıkların toplamı 1 olur:

$\Sigma_{(i=1 \to K)} P(y = i) = 1$

---

6. Softmax Örnek Hesaplama

Model Çıkış Logit Değerleri

Sınıf	Logit Değeri
cat	2.1
dog	1.2
car	0.3

Üstel Değerler

Sınıf	Hesaplama	Sonuç
cat	$e^{2.1}$	8.17
dog	$e^{1.2}$	3.32
car	$e^{0.3}$	1.35

Toplam Üstel Değer

İşlem	Sonuç
8.17 + 3.32 + 1.35	12.84

Softmax Olasılıkları

Sınıf	Hesaplama	Olasılık
cat	8.17 / 12.84	0.64
dog	3.32 / 12.84	0.26
car	1.35 / 12.84	0.10

Model Tahmini

En Yüksek Olasılık	Tahmin
0.64	cat

---

7. Sonuç

Convolution işlemi CNN modellerinin görüntülerdeki yerel özellikleri öğrenmesini sağlayan temel matematiksel işlemdir. Stride ve padding gibi hiperparametreler, elde edilen feature map boyutunu ve model performansını doğrudan etkiler.

Softmax fonksiyonu ise sinir ağlarının son katmanında kullanılarak model çıktısını olasılık dağılımına dönüştürür. Böylece model hangi sınıfın daha olası olduğunu belirleyebilir.

Bu iki matematiksel işlem, modern görüntü sınıflandırma sistemlerinin temelini oluşturmaktadır.